

Electric Vehicle Pickup and Delivery Problem with Time Windows

1st Angella Sánchez
Universidad Andrés Bello
Departamento de Ingeniería
Ingeniería Civil Informática

2nd Gianella Catalán
Universidad Andrés Bello
Departamento de Ingeniería
Ingeniería Civil Informática

3rd Vicente Hernández
Universidad Andrés Bello
Departamento de Ingeniería
Ingeniería Civil Informática

Resumen— El Problema de Recolección y Entrega con Ventanas de Tiempo para Vehículos Eléctricos (*E-PDPTW*) integra solicitudes pareadas, ventanas temporales, capacidad de carga y restricciones energéticas. Este trabajo presenta una formulación MILP estática con flota homogénea, recarga parcial y ventanas duras. Se revisan métodos exactos, metaheurísticas y aprendizaje automático. Además, se analiza *LKH-3*, extensión de Lin-Kernighan para problemas restringidos que utiliza transformaciones a TSP simétrico, penalizaciones lexicográficas y movimientos 5-opt sin reversión. La documentación de *LKH-3* reporta soporte para *PDPTW*, pero no declara batería ni recarga; por ello, se propone como motor potencial de secuenciación cuya aplicación al *E-PDPTW* requiere extensiones energéticas.

Abstract— The Electric Vehicle Pickup and Delivery Problem with Time Windows (*E-PDPTW*) combines paired requests, time windows, vehicle capacity, and battery restrictions. This paper presents a static MILP formulation with a homogeneous fleet, partial recharging, and hard time windows. Exact methods, metaheuristics, and machine-learning approaches are reviewed. In addition, *LKH-3*, a Lin-Kernighan extension for constrained routing, is studied through its transformation to symmetric TSP instances, lexicographic penalty management, and non-reversing 5-opt moves. *LKH-3* documents support for *PDPTW*, but not native battery or charging-station handling; therefore, its use for *E-PDPTW* requires energy-related extensions.

Index Terms—Electric vehicle routing, pickup and delivery, time windows, mixed-integer linear programming, metaheuristics, *LKH-3*.

I. INTRODUCCIÓN Y MOTIVACIÓN

Los problemas de recolección y entrega describen servicios en que una solicitud debe transportarse desde un origen a un destino determinado. La familia incluye variantes pareadas, no pareadas, de pasajeros y de mercadería, con diferencias en visitas, vehículos y restricciones de servicio [1]–[3]. En el *PDPTW*, cada solicitud tiene un nodo de recolección y una entrega asociada; ambas deben ser atendidas por el mismo vehículo, en el orden correcto y dentro de sus ventanas temporales [4], [5].

La electrificación agrega una fuente adicional de factibilidad: el vehículo debe mantener energía suficiente durante toda la ruta y, cuando sea necesario, recargar en estaciones compatibles con el horario planificado. La autonomía limitada, la infraestructura de carga y la duración de la recarga modifican tanto la construcción de rutas como la función objetivo [6]. En este informe se denomina *E-PDPTW* a la extensión del *PDPTW* que incorpora capacidad de batería, consumo por arco, estaciones de carga y tiempo de recarga. La variante *E-PDPTW* fue asignada para este trabajo como extensión eléctrica del *PDPTW*; por ello, el análisis de *LKH-3* se concentra en su capacidad para resolver la estructura pickup-delivery

y en las extensiones necesarias para incorporar restricciones energéticas.

El objetivo es formalizar esta variante, discutir su complejidad y revisar estrategias de solución. También se evalúa con precisión el rol de *LKH-3*. Su informe técnico enumera *PDPTW*, capacidad y ventanas de tiempo entre las variantes soportadas, pero no declara una variante eléctrica con batería y estaciones de recarga [7]. Por ello, no se lo presenta como un solver nativo de *E-PDPTW*, sino como una base potencial de búsqueda local que requiere una verificación energética adicional.

II. DEFINICIÓN FORMAL Y FORMULACIÓN MILP

II-A. Conjuntos, parámetros y variables

Se considera una flota homogénea K de vehículos eléctricos. Sea $P = \{1, \dots, n\}$ el conjunto de nodos de recolección, $D = \{n+1, \dots, 2n\}$ el de entregas y $\bar{i} = i+n$ la entrega asociada a $i \in P$. Los nodos 0 y $2n+1$ representan el depósito inicial y final. Sea F el conjunto de estaciones físicas y F' un conjunto de copias virtuales que permite modelar visitas repetidas a estaciones dentro de un grafo estático; esta práctica es coherente con formulaciones de ruteo eléctrico con ventanas de tiempo [6].

El grafo dirigido es $G = (V, A)$, donde

$$V = \{0, 2n+1\} \cup P \cup D \cup F'. \quad (1)$$

Para cada arco $(i, j) \in A$ se conocen costo c_{ij} , tiempo de viaje τ_{ij} y consumo ε_{ij} . La demanda q_i es positiva en P , negativa en D y nula en depósitos y estaciones. Cada nodo tiene ventana $[e_i, l_i]$ y servicio s_i ; Q y B denotan capacidad de carga y batería, y r_f la tasa de recarga de $f \in F'$.

Las variables principales son $x_{ij}^k \in \{0, 1\}$, que indica uso del arco; $v_i^k \in \{0, 1\}$, visita del nodo; T_i^k , inicio de servicio; L_i^k , carga; b_i^k y y_i^k , energía al llegar y salir; g_i^k , energía recargada; y θ_i^k , tiempo de carga. Se usan cotas Big- M diferenciadas: M^T para tiempo, $M^L = Q + \max_{i \in V} |q_i|$ para carga y $M^B = B + \max_{(i,j) \in A} \varepsilon_{ij}$ para energía. Estas cotas tienen unidades coherentes y relajan sólo el recurso correspondiente cuando un arco no se usa.

II-B. Supuestos de la variante estudiada

La formulación corresponde a una variante estática: todas las solicitudes se conocen antes de iniciar la planificación.

Esta decisión permite concentrar el análisis en la combinación de precedencia, tiempo, capacidad y energía. La literatura distingue problemas estáticos, dinámicos y estocásticos según la disponibilidad de la información; en los dos últimos, la ruta debe actualizarse al aparecer pedidos o al cambiar los datos de viaje [1], [8]. Se asume una flota homogénea, un depósito inicial y final, ventanas de tiempo duras y recarga parcial en estaciones. No se modelan colas, incompatibilidad entre conectores, degradación de batería ni una curva no lineal de carga. Estas simplificaciones no niegan su importancia: delimitan un modelo base verificable antes de incorporar efectos que aumentan la dificultad práctica del *E-VRP* [6].

La notación conserva la estructura de los PDP pareados: el par $(i, \bar{i})$ representa una misma solicitud, por lo que la entrega no puede atenderse con otro vehículo ni antes de su recolección. Esta diferencia es central frente a modelos de backhauls, donde las recogidas y entregas no necesariamente forman pares uno-a-uno [2], [3].

II-C. Objetivo, ruteo y precedencia

La función objetivo minimiza el costo operativo total:

$$\min \sum_{k \in K} \sum_{(i,j) \in A} c_{ij} x_{ij}^k. \quad (2)$$

Cada cliente se atiende una vez y el flujo se conserva:

$$\sum_{k \in K} \sum_{j: (i,j) \in A} x_{ij}^k = 1, \quad \forall i \in P \cup D, \quad (3)$$

$$\sum_{j: (i,j) \in A} x_{ij}^k = \sum_{j: (j,i) \in A} x_{ji}^k, \quad \forall i \in P \cup D \cup F', \quad k \in K. \quad (4)$$

Cada vehículo puede activar a lo más una ruta, la cual parte en el depósito inicial y termina en el final:

$$\sum_{j: (0,j) \in A} x_{0j}^k = \sum_{i: (i,2n+1) \in A} x_{i,2n+1}^k \leq 1, \quad \forall k \in K. \quad (5)$$

Se vincula la visita de todos los nodos de servicio con el arco saliente. Luego se fuerza que cada solicitud sea atendida por el mismo vehículo:

$$v_i^k = \sum_{j: (i,j) \in A} x_{ij}^k, \quad \forall i \in P \cup D \cup F', \quad k \in K, \quad (6)$$

$$v_i^k = v_{\bar{i}}^k, \quad \forall i \in P, \quad k \in K. \quad (7)$$

La primera igualdad también vincula v_f^k con la visita efectiva a una estación $f \in F'$. La segunda impide que un vehículo realice la recolección y otro complete la entrega. En aplicaciones de pasajeros, una formulación análoga permite expresar consistencia de ruta, tiempo de viaje y calidad de servicio [9].

II-D. Tiempo, carga y energía

Para todo $i \in P \cup D \cup F'$ y $k \in K$, las ventanas de tiempo son duras:

$$e_i - M^T(1 - v_i^k) \leq T_i^k \leq l_i + M^T(1 - v_i^k). \quad (8)$$

Para todo $(i,j) \in A$ y $k \in K$, la propagación temporal incorpora servicio, recarga y viaje:

$$T_j^k \geq T_i^k + s_i + \theta_i^k + \tau_{ij} - M^T(1 - x_{ij}^k). \quad (9)$$

Finalmente, para todo $i \in P$ y $k \in K$, la precedencia obliga a realizar primero la recolección:

$$T_i^k \geq T_i^k + s_i - M^T(1 - v_i^k). \quad (10)$$

La carga se actualiza exactamente al recorrer un arco:

$$\begin{aligned} L_j^k &\geq L_i^k + q_j - M^L(1 - x_{ij}^k), \\ L_j^k &\leq L_i^k + q_j + M^L(1 - x_{ij}^k), \\ 0 &\leq L_i^k \leq Q, \quad L_0^k = 0. \end{aligned} \quad (11)$$

Finalmente, la batería se propaga según consumo y recarga:

$$\begin{aligned} b_j^k &\geq y_i^k - \varepsilon_{ij} - M^B(1 - x_{ij}^k), \\ b_j^k &\leq y_i^k - \varepsilon_{ij} + M^B(1 - x_{ij}^k), \\ y_i^k &= b_i^k + g_i^k. \end{aligned} \quad (12)$$

Fuera de estaciones, $g_i^k = \theta_i^k = 0$. Para $f \in F'$:

$$0 \leq g_f^k \leq B v_f^k, \quad b_f^k + g_f^k \leq B, \quad g_f^k = r_f \theta_f^k, \quad (13)$$

con $0 \leq b_i^k, y_i^k \leq B$ y $y_0^k = B$. Las ecuaciones de carga y energía se presentan en pares de desigualdades porque una sola cota no basta para imponer la actualización exacta al usar un arco. Usar M^T , M^L y M^B en vez de una sola constante evita mezclar horas, unidades de carga y energía, y fortalece la relajación lineal. También se observa que la propagación temporal es una restricción de recurso con Big- M , no una MTZ clásica: su función es conectar servicio, recarga y viaje en la ruta elegida.

El modelo usa consumo fijo por arco y una tasa de recarga constante. Para operaciones reales, el consumo puede depender de velocidad, tiempo de viaje, carga transportada, pendiente o temperatura; la recarga puede requerir disponibilidad de cargador y una curva no lineal. La variante con tiempos estocásticos y dependientes del tiempo de Wang *et al.* ilustra que, aun sin energía, la confiabilidad temporal obliga a incorporar información probabilística y niveles de servicio [10]. Por ello, las extensiones energéticas se recomiendan después de validar este modelo base.

III. ESTADO DEL ARTE

Los métodos exactos suelen formular rutas como columnas de un problema maestro de partición de conjuntos. Para problemas pickup-delivery, la literatura reporta branch-and-price, branch-and-cut y extensiones que controlan recursos de capacidad y tiempo [4], [9], [10]. El subproblema de precios suele buscar caminos factibles bajo recursos acumulados; por eso ventanas, carga y precedencia no son detalles accesorios, sino parte de la estructura que vuelve costosa la enumeración de rutas. Su valor principal es entregar óptimos o cotas verificables, pero su escalabilidad disminuye con el número de solicitudes y restricciones.

Kim *et al.* proponen descomposición temporal con horizonte rodante para instancias PDPTW de gran escala. Su idea es

resolver secuencias de subproblemas con intervalos solapados, evitando cortar por completo las rutas en las fronteras temporales [11]. Esta estrategia no reemplaza el modelo completo, pero muestra una forma de intercambiar exactitud global por tractabilidad cuando las instancias alcanzan miles de solicitudes.

Las heurísticas constructivas e inserciones ofrecen una base rápida para rutas factibles. Sobre ellas, las metaheurísticas exploran vecindarios y equilibran intensificación y diversificación: búsqueda tabú, recocido simulado, VNS, ACO, algoritmos genéticos y métodos meméticos se emplean como familias generales en ruteo. Para PDPTW, Pankratz estudia un algoritmo genético de agrupamiento donde cada gen representa un conjunto de solicitudes; la codificación intenta preservar compatibilidad antes de secuenciar rutas [4]. Ropke y Pisinger desarrollan una ALNS específica que alterna operadores de destrucción y reparación según su rendimiento histórico y la evalúan en más de 350 instancias de hasta 500 solicitudes [5].

En la variante eléctrica, la fase de reparación debe preservar no sólo precedencia y capacidad, sino también la posibilidad de recargar a tiempo. Una inserción que acorta distancia puede ser inviable si deja el estado de carga bajo cero o desplaza el inicio de servicio más allá del límite de una ventana [6].

Los algoritmos meméticos combinan población y búsqueda local. Zhou *et al.* aplican este enfoque a un DPDP industrial de Huawei, con pedidos liberados periódicamente, capacidad, ventanas y hasta miles de solicitudes; el algoritmo equilibra exploración mediante evolución y explotación mediante mejora local [8]. Este resultado es relevante para E-PDPTW porque, incluso antes de incluir batería, la reoptimización ante nuevos pedidos ya tensiona el tiempo de respuesta.

Horváth y Kis advierten que en problemas dinámicos los resultados pueden ser engañosos si se relajan restricciones o se alteran herramientas de benchmark sin declararlo [12]. Por ello, una comparación responsable debe mantener instancia, simulador, conjunto de restricciones y criterio objetivo; de lo contrario, una mejora numérica puede provenir de un problema más fácil y no de un algoritmo superior.

El aprendizaje automático ofrece políticas de decisión aprendidas. Kool *et al.* proponen un modelo de atención entrenado mediante refuerzo para TSP y variantes de VRP; la ruta se construye secuencialmente a partir de una representación del grafo [13]. En escenarios dinámicos, Mustakhov *et al.* emplean DRL con codificador-decodificador basado en atención para responder a pedidos que aparecen durante la operación [14].

Las revisiones recientes distinguen modelos end-to-end, GNN, aprendizaje supervisado, RL e híbridos que incorporan heurísticas o solvers tradicionales [15], [16]. La principal promesa es reducir tiempo de decisión después del entrenamiento; la principal limitación es que una política entrenada en cierta distribución de instancias puede degradarse al cambiar tamaño, geografía, cantidad de vehículos o restricciones. En E-PDPTW, un enfoque de aprendizaje debe acoplarse a un verificador determinista de carga, ventanas y batería antes de aceptar una ruta.

Cuadro I
COMPARACIÓN SINTÉTICA DE FAMILIAS DE SOLUCIÓN.

Familia	Fortaleza	Riesgo en E-PDPTW
Exactos	Óptimo o cota verificable	Escalan mal con tiempo, carga y batería.
ALNS / Tabú / VNS / SA / ACO	Exploran vecindarios amplios	Deben reparar recarga y ventanas.
Genético / memético	Diversidad más mejora local	El cromosoma debe mantener precedencia.
DRL / GNN / híbridos	Decisiones rápidas tras entrenar	Generalización y factibilidad requieren control.
LKH-3	Búsqueda local especializada	No documenta batería ni estaciones.




Figura 1. Resultados agregados reportados por Pankratz para su GGA frente a recocido simulado. Fuente: adaptado del material entregado por Pankratz [4].

IV. COMPLEJIDAD Y APLICACIONES INDUSTRIALES

El PDPTW es NP-hard porque generaliza problemas de ruteo con ventanas de tiempo; Pankratz lo relaciona con la dificultad del VRPTW [4]. El E-PDPTW conserva esa dificultad: una instancia PDPTW se obtiene fijando batería no restrictiva, $\varepsilon_{ij} = 0$ y $F' = \emptyset$. Esta transformación es polinomial y preserva costo y factibilidad, por lo que el E-PDPTW también es NP-hard. Luego se añaden decisiones de recarga, energía y compatibilidad de infraestructura [6].

Tres aplicaciones ilustran su utilidad. Primero, distribución urbana y última milla con flotas eléctricas: la empresa debe servir clientes con ventanas comprometidas sin agotar autonomía ni transformar cada recarga en una espera excesiva [6]. Segundo, transporte de pacientes y *dial-a-ride*: las solicitudes pareadas deben cumplir horarios de recogida y entrega y, en varias aplicaciones, la calidad de servicio se mide también mediante tiempo de viaje o espera [9]. Tercero, paratransito y transporte bajo demanda con ventanas estrechas, donde Kim *et al.* estudian PDPTW a gran escala mediante horizonte rodante [11]. En una extensión industrial dinámica, Zhou *et al.* muestran la necesidad de reoptimizar frente a nuevos pedidos y restricciones operativas [8].

Estos casos exigen indicadores distintos. Para última milla interesa costo, distancia, energía recargada y cumplimiento de promesa; para pacientes, puntualidad y tiempo de viaje; para planificación dinámica, solicitudes atendidas, tardanza y tiempo de reoptimización. Reportar sólo distancia puede ocultar una ruta eléctrica inviable o una solución que mejora costo a cambio de deteriorar nivel de servicio.

V. LKH-3 APLICADO AL E-PDPTW

V-A. Transformación y evaluación lexicográfica

LKH-3 extiende Lin-Kernighan para TSP y VRP restringidos. El informe describe una transformación de problemas asimétricos de n nodos a TSP simétricos de $2n$ nodos y, para múltiples vehículos, la inserción de copias del depósito con costos infinitos entre ellas [7]. Cada tour se evalúa con el par (P, C) : P mide violaciones de restricciones y C el costo. La comparación es lexicográfica:

$$(P_1, C_1) \prec (P_2, C_2) \iff P_1 < P_2 \text{ o } (P_1 = P_2 \wedge C_1 < C_2). \quad (14)$$

Para un prototipo *E-PDPTW*, una extensión razonable es incluir en P batería negativa, recargas fuera de estación o exceso de capacidad. Esta es una propuesta derivada de la arquitectura de penalizaciones de *LKH-3*, no una funcionalidad nativa documentada.

V-B. Movimientos y alcance

La evaluación de penalizaciones puede requerir $O(N)$ en el peor caso. Para reducir movimientos, *LKH-3* usa un generador 5-opt que privilegia cambios sin reversión de segmentos y explora de forma restringida movimientos 4-opt, 5-opt y 6-opt [7]. La restricción es coherente con precedencia pickup-delivery, porque invertir segmentos puede alterar el orden de servicio.

El informe de *LKH-3* también documenta perturbación *double-bridge* y una configuración genética con población de 10 soluciones. El mecanismo de perturbación evita que la búsqueda se estanque en un óptimo local, mientras la recombinación permite conservar aristas o estructuras presentes en soluciones de buena calidad [7]. En los benchmarks PDPTW reporta 3 resultados mejores y 180 iguales a la mejor solución conocida: 183 de 222 instancias igualadas o mejoradas. Esa evidencia es fuerte para PDPTW, pero no prueba desempeño en E-PDPTW.

Antes de comparar con metaheurísticas eléctricas, la extensión debe verificarse contra el MILP en instancias pequeñas. Una prueba mínima consiste en construir rutas donde la secuencia es correcta pero la batería es insuficiente; si el valor de P no aumenta, entonces el motor de búsqueda estaría optimizando una representación incompleta del problema.

VI. DISCUSIÓN, BRECHAS Y TRABAJO FUTURO

El modelo integra ruteo, tiempo, carga y energía de manera explícita. El siguiente paso es resolver instancias pequeñas con el MILP y usar pruebas unitarias que rechacen: entrega antes de recolección, sobrecapacidad, llegada fuera de ventana y batería negativa. Luego se puede comparar una inserción constructiva con ALNS, algoritmo genético, enfoque memético o una extensión de *LKH-3*.

El protocolo experimental debe fijar las mismas instancias, horizonte temporal, objetivo y límites de ejecución para todos los métodos. En algoritmos aleatorios se recomienda informar varias corridas, mejor valor, promedio, desviación y porcentaje de rutas factibles. Para el modelo exacto se deben reportar

óptimo, cota o brecha al detenerse. Esta separación evita comparar una solución factible de alta calidad contra otra que parece más barata porque omite consumo, tiempo de carga o alguna ventana.

Las brechas relevantes son consumo dependiente de carga o velocidad, tiempos de viaje estocásticos, curvas de carga no lineales, disponibilidad limitada de cargadores y decisiones dinámicas. Wang *et al.* muestran que la incertidumbre temporal exige considerar confiabilidad de servicio, mientras los trabajos de aprendizaje recientes se orientan a respuestas rápidas, pero todavía requieren una validación robusta de restricciones [10], [15], [16]. La fidelidad del benchmark debe documentarse con cuidado para que las comparaciones sean reproducibles [12].

VII. PROPUESTA DE IMPLEMENTACIÓN Y EVALUACIÓN

La implementación puede organizarse en tres niveles. En el primero, el MILP se resuelve sobre instancias pequeñas para comprobar que las ecuaciones representen el comportamiento esperado. Esto incluye probar rutas con una sola solicitud, con dos solicitudes compatibles y con una recarga obligatoria. Cada caso debe verificarse manualmente: el tiempo de llegada debe respetar la propagación temporal, la carga debe cambiar en el signo correcto y el estado de batería debe disminuir exactamente en ε_{ij} al recorrer cada arco. El objetivo de esta etapa no es competir en tiempo de cómputo, sino detectar errores de formulación antes de escalar la instancia.

En el segundo nivel se construye una heurística base de inserción. Para cada solicitud no atendida se evalúan posiciones factibles de pickup y delivery dentro de una ruta; si la energía no alcanza, se prueba insertar una estación de carga virtual. La mejor inserción no debe elegirse sólo por menor incremento de distancia, sino por el costo incremental total y por mantener factibilidad de tiempo, capacidad y batería. Esta línea base permite comparar de forma honesta las ganancias de ALNS, algoritmo genético o *LKH-3* extendido. La filosofía de separar construcción y mejora local es consistente con las metaheurísticas revisadas para PDPTW [4], [5].

En el tercer nivel se incorpora una metaheurística. En ALNS, los operadores de destrucción pueden eliminar solicitudes relacionadas geográfica o temporalmente; los de reparación vuelven a insertar el par pickup-delivery y, de ser necesario, estaciones. En una extensión de *LKH-3*, la función de penalización debe recalcular recursos de manera incremental y distinguir entre una ruta barata pero infactible y una ruta factible de mayor costo. Para instancias dinámicas, un horizonte rodante permite congelar la parte ya ejecutada y reoptimizar la parte futura cuando llegan nuevas solicitudes [8], [11].

La evaluación debe informar al menos: costo total, distancia, tiempo de ejecución, cantidad de vehículos usados, porcentaje de solicitudes atendidas, tardanza, energía recargada y número de visitas a estaciones. Para variantes con incertidumbre se recomienda agregar nivel de servicio o probabilidad de cumplir ventanas, como propone Wang *et al.* [10]. Finalmente, el código, la semilla aleatoria, los parámetros y el preprocesamiento

de instancias deben quedar documentados. La advertencia de Horváth y Kis sobre benchmarks dinámicos muestra que la reproducibilidad no es un detalle editorial: es parte de la validez del resultado [12].

VII-A. Limitaciones del modelo y criterios de comparación

El modelo no pretende capturar todos los fenómenos de una operación eléctrica real. Se asume que una estación siempre está disponible cuando la ruta la visita, que la tasa r_f es constante y que el consumo de cada arco es conocido. En una red urbana estos supuestos pueden fallar: la disponibilidad de cargadores puede generar espera, el tráfico modifica la llegada y la energía consumida puede depender de la velocidad y de la carga. La ventaja del modelo base es que permite identificar de forma separada el efecto de cada recurso; la desventaja es que sus resultados deben interpretarse como una cota estructural y no como una simulación completa de la operación [6], [10].

Para comparar alternativas, la jerarquía de criterios debe declararse de manera explícita. Una opción es priorizar factibilidad y luego costo: primero se minimizan solicitudes no atendidas y violaciones de recursos; entre las soluciones factibles, se minimiza distancia, tiempo o costo monetario. Otra opción es usar penalizaciones ponderadas, pero en ese caso se deben justificar los pesos y verificar que no permitan aceptar rutas baratas con incumplimientos severos. La evaluación lexicográfica de *LKH-3* ilustra esta separación entre penalización y costo [7]; el mismo principio es particularmente útil cuando una batería negativa o una entrega tardía no pueden compensarse con una distancia menor.

Finalmente, la comparación entre un modelo exacto, una metaheurística y un enfoque de aprendizaje debe reconocer que responden a preguntas distintas. El MILP sirve para validar optimalidad o cotas en instancias pequeñas; ALNS, VNS o algoritmos genéticos sirven para obtener buenas rutas en tiempo limitado; y DRL o GNN pueden producir decisiones rápidas tras entrenamiento. Por tanto, un resultado creíble no consiste sólo en declarar un mejor costo: debe indicar el tamaño de instancia, el hardware, el tiempo de ejecución, la semilla, la tasa de factibilidad y el conjunto exacto de restricciones utilizado [5], [15], [16].

VIII. DECLARACIÓN DE USO DE IA

Se utilizó una herramienta de inteligencia artificial generativa como apoyo para organizar la redacción, revisar consistencia de notación y estructurar referencias bibliográficas. La selección final de fuentes, la verificación de las referencias, el análisis técnico y la versión final del documento fueron revisados por los autores.

REFERENCIAS

- [1] G. Berbeglia, J.-F. Cordeau, I. Gribkovskaia, and G. Laporte, "Static pickup and delivery problems: A classification scheme and survey," *TOP*, vol. 15, no. 1, pp. 1–31, 2007.
- [2] S. N. Parragh, K. F. Doerner, and R. F. Hartl, "A survey on pickup and delivery problems: Part I: Transportation between customers and depot," *Journal für Betriebswirtschaft*, vol. 58, pp. 21–51, 2008.
- [3] —, "A survey on pickup and delivery problems: Part II: Transportation between pickup and delivery locations," *Journal für Betriebswirtschaft*, vol. 58, pp. 81–117, 2008.
- [4] G. Pankratz, "A grouping genetic algorithm for the pickup and delivery problem with time windows," *OR Spectrum*, vol. 27, no. 1, pp. 21–41, 2005.
- [5] S. Ropke and D. Pisinger, "An adaptive large neighborhood search heuristic for the pickup and delivery problem with time windows," *Transportation Science*, vol. 40, no. 4, pp. 455–472, 2006.
- [6] T. Erdelić and T. Carić, "A survey on the electric vehicle routing problem: Variants and solution approaches," *Journal of Advanced Transportation*, vol. 2019, p. 5075671, 2019.
- [7] K. Helsgaun, "An extension of the lin–kernighan–helsgaun TSP solver for constrained traveling salesman and vehicle routing problems," Roskilde University, Technical Report, 2017.
- [8] Y. Zhou, L. Kong, L. Yan, Y. Liu, and H. Wang, "A memetic algorithm for a real-world dynamic pickup and delivery problem," *Memetic Computing*, vol. 16, pp. 203–217, 2024.
- [9] J.-F. Cordeau, "A branch-and-cut algorithm for the dial-a-ride problem," *Operations Research*, vol. 54, no. 3, pp. 573–586, 2006.
- [10] Z. Wang, M. Dessouky, T. V. Woensel, and P. Ioannou, "Pickup and delivery problem with hard time windows considering stochastic and time-dependent travel times," *EURO Journal on Transportation and Logistics*, vol. 12, p. 100099, 2023.
- [11] Y. Kim, D. Edirimanna, M. Wilbur, P. Pugliese, A. Laszka, A. Dubey, and S. Samaranayake, "Rolling horizon based temporal decomposition for the offline pickup and delivery problem with time windows," in *Proceedings of the Thirty-Seventh AAAI Conference on Artificial Intelligence*, 2023, pp. 5151–5159.
- [12] M. Horváth and T. Kis, "On recent computational results for a dynamic pickup and delivery problem," *Memetic Computing*, vol. 17, p. 27, 2025.
- [13] W. Kool, H. van Hoof, and M. Welling, "Attention, learn to solve routing problems!" in *International Conference on Learning Representations*, 2019.
- [14] T. Mustakhov, Y. Akhmetbek, and A. Bogrybayeva, "Deep reinforcement learning for stochastic dynamic vehicle routing problem," in *2023 17th International Conference on Electronics Computer and Computation*, 2023.
- [15] R. Shahbazian, L. D. P. Pugliese, F. Guerriero, and G. Macrina, "Integrating machine learning into vehicle routing problem: Methods and applications," *IEEE Access*, vol. 12, pp. 93 087–93 115, 2024.
- [16] A. Bogrybayeva, M. Meraliyev, T. Mustakhov, and B. Dautbayev, "Machine learning to solve vehicle routing problems: A survey," *IEEE Transactions on Intelligent Transportation Systems*, vol. 25, no. 6, pp. 4754–4772, 2024.